

Pipeline de Producto — Documento Técnico

Trabajo de Fin de Máster · Data Analytics

Iker Lleida · June 2026

1. Resumen Ejecutivo

Este documento describe el diseño, implementación y resultados del sistema de predicción de satisfacción laboral de empleados de NVIDIA desarrollado como parte del Trabajo de Fin de Máster en Data Analytics. El sistema combina técnicas avanzadas de Procesamiento del Lenguaje Natural (NLP) con modelos de Machine Learning para estimar, en tiempo real, el nivel de satisfacción de un empleado a partir de una review textual.

El pipeline de producto completo abarca desde la recogida de datos mediante un formulario web hasta la visualización automática en un dashboard de Tableau Desktop, pasando por un motor de predicción basado en XGBoost entrenado sobre 356.594 reviews de empleados de empresas del S&P; 500 extraídas de Glassdoor.

356.594	267	0.655	0.731	500	<2s
Reviews de entrenamiento	Features del modelo	R ² en datos P1	RMSE en datos P1	Empresas S&P; 500	Latencia predicción

2. Problema y Motivación

La satisfacción laboral es un predictor crítico de la retención de talento, la productividad y el bienestar organizacional. Sin embargo, las encuestas tradicionales tienen baja tasa de respuesta y capturan únicamente métricas cuantitativas, perdiendo el rico contenido semántico presente en el texto libre de las reviews de empleados.

Objetivo principal

Desarrollar un modelo de predicción que, dado el texto libre de una review de empleado (resumen, pros, contras), estime automáticamente el **overall_rating** en escala 1–5 y lo clasifique como **Alto** (≥ 4) o **Bajo** (< 4), integrando además variables contextuales de la empresa, sector y mercado.

Caso de uso: NVIDIA

NVIDIA (ticker: NVDA) se utiliza como empresa piloto para la demo en tiempo real. Con 945 reviews históricas disponibles y una distribución de satisfacción predominantemente positiva (68% Alto), sirve como banco de pruebas ideal para validar el pipeline end-to-end.

3. Datos

3.1 Fuente de datos

Las reviews fueron extraídas de **Glassdoor** mediante web scraping para las 500 empresas del índice S&P; 500. Cada review incluye texto libre (summary, pros, cons) y valoraciones numéricas en seis dimensiones: work-life balance, culture & values, diversity & inclusion, career opportunities, compensation & benefits, y senior management.

3.2 Enriquecimiento

A cada review se le añadieron variables contextuales externas:

- Datos de empresa: capitalización bursátil, número de empleados, año de fundación, sector (GICS).
- Datos de mercado: variación porcentual del precio de la acción a 1 mes y 1 año (yfinance).
- Datos macroeconómicos del estado del empleado: PIB per cápita, temperatura media, índice de criminalidad, etc.
- Variables temporales: mes, año y días desde la fundación de la empresa hasta la review.

3.3 Preprocesamiento

Se aplicó **StandardScaler** a todas las features numéricas, **One-Hot Encoding** para sector y estado, y **Target Encoding** (media y mediana del target por categoría) para capturar el efecto de sector y estado sobre la satisfacción. El split train/test fue 80/20 estratificado, resultando en 285.275 reviews de entrenamiento y 71.319 de test.

4. Feature Engineering (267 features)

El feature engineering es el núcleo del sistema. Se extraen 267 features distribuidas en 13 grupos que capturan distintas dimensiones del contenido textual y el contexto empresarial:

Grupo de Features	Nº Features	Herramienta / Fuente
POS tag frequencies	~120	NLTK pos_tag (Penn Treebank)
EmoLex affect scores	20	NRClex (pros + cons × 10 emociones)
Empath scores	40	Empath (pros + cons × 20 categorías)
VADER sentiment	2	NLTK SentimentIntensityAnalyzer
JDI cosine similarities	10	SentenceTransformer all-roberta-large-v1
ODI cosine similarities	18	SentenceTransformer all-roberta-large-v1
ODI vocabulary ratio	2	Keyword matching (9 dimensiones clínicas)
Text lengths	6	charlen + wordlen (summary, pros, cons)
Company features	4	Market Cap, Employees, Founded, Cap/Employee
Sector OHE + target enc.	21	19 sectores + Sector_targenc_mean/median
Stock % change	4	yfinance (NVDA + SPY, mes + año)
Temporal features	5	month, year, days desde fundación / t0
State features	~15	OHE + target encoding (Estado del empleado)
TOTAL	267	

4.1 Similitudes semánticas JDI / ODI

Se calculan similitudes coseno entre el embedding de pros/cons del empleado y vectores de referencia de dos marcos teóricos: el **Job Descriptive Index (JDI)** con 5 dimensiones (trabajo en sí, salario, promoción, supervisión, compañeros) y el **Organizational Depression Index (ODI)** con 9 dimensiones clínicas (ánimo depresivo, alteraciones del sueño, fatiga, etc.). Los embeddings se generan con el

modelo **all-roberta-large-v1** (1024 dimensiones).

5. Modelo de Machine Learning

5.1 Selección de modelo

Se evaluaron múltiples algoritmos (ElasticNet, K-Nearest Neighbors, Decision Tree, Random Forest, XGBoost) mediante validación cruzada con 5 folds, optimizando el **neg_root_mean_squared_error**. XGBoost Regressor fue seleccionado como modelo final por su rendimiento superior y capacidad para capturar interacciones no lineales entre features.

5.2 Hiperparámetros del modelo final

Parámetro	Valor
n_estimators	500
max_depth	9
learning_rate	0.05
objective	reg:squarederror
tree_method	hist
random_state	8

5.3 Features más importantes (Top 5)

- 1º cons_sim_ODI_Worthlessness — importancia: 0.0847
- 2º cons_charlen — importancia: 0.0508
- 3º pros_nltk_sia — importancia: 0.0318
- 4º cons_emolex_disgust — importancia: 0.0207
- 5º pros_charlen — importancia: 0.0194

5.4 Nota sobre serialización

El modelo fue entrenado con sklearn 1.7.2 y XGBoost 2.x en el entorno de entrenamiento. Al cargarlo con sklearn 1.4.2 (entorno local), el base_score de XGBoost no se restaura correctamente desde el pickle, produciendo un desplazamiento sistemático en las predicciones. Esto se diagnosticó y documentó durante el desarrollo del pipeline de producción.

6. Pipeline de Producto en Tiempo Real

El sistema de demo en tiempo real implementa un pipeline end-to-end completamente automatizado que conecta la recogida de feedback del empleado con la visualización de la predicción en un dashboard analítico:

Tally.so → ngrok → n8n → FastAPI /predict → gold.xlsx → Tableau Desktop

Componente	Tecnología	Función
Formulario	Tally.so	Recoge la review del empleado
Orquestador	n8n (Node.js v20)	Recibe webhook y coordina el pipeline
API de predicción	FastAPI + Uvicorn	Feature engineering + inferencia XGBoost
Modelo ML	XGBoost Regressor	Predice overall_rating (escala 1–5)
Almacenamiento	gold.xlsx (openpyxl)	Histórico acumulativo de predicciones
Visualización	Tableau Desktop	Dashboard en tiempo real
Túnel público	ngrok	Expone n8n a internet para Tally

6.1 Flujo de datos

- **1. Empleado:** Rellena el formulario Tally.so con: summary, pros, cons, y 6 ratings numéricos (1–5).
- **2. Tally → n8n:** Tally envía un webhook POST al endpoint público de ngrok que tuneliza a n8n (localhost:5678).
- **3. n8n Parse:** El nodo 'Parse Tally Fields' extrae los campos del JSON de Tally y los normaliza.
- **4. n8n → FastAPI:** HTTP POST a localhost:8000/predict con los campos de texto y ratings.
- **5. Feature Engineering:** La FastAPI computa 267 features en tiempo real: POS tags, EmoLex, Empath, VADER, similitudes JDI/ODI, datos de empresa y mercado.
- **6. Predicción XGBoost:** El modelo infiere el overall_rating (1–5) y binariza: $\geq 4 \rightarrow$ Alto, $< 4 \rightarrow$ Bajo.
- **7. Append Excel:** POST a /append-gold: openpyxl añade la nueva fila al gold.xlsx.
- **8. Tableau:** Cmd+Shift+F5 refresca la conexión Live al Excel y la nueva predicción aparece en el dashboard.

6.2 Campos del formulario Tally

- **summary** (Texto corto): Resumen de la experiencia del empleado
- **pros** (Texto largo): Lo mejor de trabajar en la empresa
- **cons** (Texto largo): Aspectos a mejorar
- **wl_balance** (Escala 1–5): Work-life balance
- **culture_values** (Escala 1–5): Cultura y valores
- **diversity_inclusion** (Escala 1–5): Diversidad e inclusión
- **career_opportunities** (Escala 1–5): Oportunidades de carrera
- **compensation_benefits** (Escala 1–5): Compensación y beneficios
- **senior_management** (Escala 1–5): Alta dirección
- **department** (Desplegable): Departamento del empleado
- **seniority** (Desplegable): Nivel de seniority
- **gender** (Desplegable): Género (opcional)

7. Estructura del Gold Dataset

El fichero **gold.xlsx** actúa como repositorio central de predicciones, combinando 945 reviews históricas de NVIDIA (batch predict) con las nuevas submissions en tiempo real. Sirve como fuente de datos para Tableau Desktop.

Columna	Tipo	Descripción
timestamp	Datetime	Fecha y hora de la predicción (ISO 8601)
submission_date	Date	Fecha de la review
summary	String	Texto del resumen
pros	String	Texto de pros
cons	String	Texto de cons
department	String	Departamento del empleado
seniority	String	Nivel de seniority / job title
gender	String	Género
wl_balance	Float	Work-life balance (1–5)
culture_values	Float	Cultura y valores (1–5)
diversity_inclusion	Float	Diversidad e inclusión (1–5)
career_opportunities	Float	Oportunidades de carrera (1–5)
compensation_benefits	Float	Compensación (1–5)
senior_management	Float	Alta dirección (1–5)
predicted_rating	Float	Predicción del modelo (1.0–5.0)
satisfaction	String	Binarización: Alto (≥ 4) / Bajo (< 4)
confidence	Float	Distancia al umbral normalizada (0–1)

8. Stack Tecnológico

Capa	Tecnología	Versión
ML / Modelo	XGBoost Regressor	2.0.3
Feature Engineering	NLTK, NRCLEx, Empath, VADER	—
Embeddings	sentence-transformers	all-roberta-large-v1
API	FastAPI + Uvicorn	0.115 / 0.32
Orquestación	n8n	2.27.4
Datos	pandas, openpyxl	2.x / 3.1.4
Formulario	Tally.so	—
Túnel	ngrok	3.39.8
Visualización	Tableau Desktop	—

Runtime	Python 3.11 / Node.js 20	—
Entorno	Anaconda (macOS)	—

9. Limitaciones y Trabajo Futuro

9.1 Limitaciones actuales

- El modelo fue entrenado exclusivamente con datos de empresas del S&P; 500 estadounidenses; su generalización a otros mercados o sectores requiere validación adicional.
- Las features de empresa (Market Cap, sector) están hardcodedas para NVIDIA en el pipeline de tiempo real; para otras empresas sería necesario parametrizar el endpoint.
- La incompatibilidad entre sklearn 1.7.2 (entrenamiento) y 1.4.2 (producción) genera un desplazamiento en el base_score de XGBoost que afecta a la escala absoluta de las predicciones.
- El dashboard requiere refresh manual en Tableau Desktop; una solución de producción utilizaría Tableau Server o Tableau Cloud con scheduled extracts.
- ngrok en plan gratuito genera una URL distinta en cada reinicio, lo que requiere actualizar el webhook de Tally.so.

9.2 Trabajo futuro

- Despliegue del modelo en Google Cloud Vertex AI para mayor escalabilidad y latencia controlada.
- Entrenamiento de modelos específicos por empresa o sector para mejorar la precisión.
- Implementación de fine-tuning de modelos de lenguaje (BERT, RoBERTa) como alternativa al feature engineering manual.
- Integración de análisis de sentimiento a nivel de aspecto (ABSA) para descomponer la satisfacción por dimensión JDI/ODI.
- Dashboard en Tableau Cloud con refresh automático y alertas en tiempo real.

10. Conclusiones

Este trabajo demuestra la viabilidad de construir un sistema de predicción de satisfacción laboral en tiempo real combinando NLP clásico, embeddings contextuales y modelos de gradient boosting. El pipeline implementado va más allá del prototipo académico: es un producto funcional con integración end-to-end entre formulario web, API de predicción y dashboard analítico, ejecutándose en tiempo real con una latencia inferior a 2 segundos.

La aplicación a NVIDIA demuestra que el modelo captura patrones semánticos significativos en las reviews de empleados: la importancia de features como *cons_sim_ODI_Worthlessness* o *cons_emolex_disgust* revela que el modelo ha aprendido a identificar señales de malestar laboral directamente del texto, sin necesidad de labels explícitos sobre dimensiones psicológicas.

El pipeline de producto valida la arquitectura propuesta como base para un sistema de monitorización continua del clima laboral corporativo, con potencial de escalado a cualquier empresa con suficiente volumen de feedback textual de empleados.